

סיכום עיבוד תמונה וראייה ממוחשבת:

סילבוס:

- Topic 1 – Image Enhancement: histogram, quantization
- Topic 2 – Filtering: smoothing, median filtering, sharpening – Low level detection: Template matching, Edges, Line, Circles
- Topic 3 – Image Pyramids and Blending, Optical Flow
- Topic 4 – Geometry: 2D Transformation, Image Warping, Camera Model
- Topic 5 – Stereo – Homography, Image rectification, Image Stitching (Mosaic/Panorama)
- Topic 6 – Features, Robust Estimation, RANSAC
- Topic 7 – Single view geometry
- Topic 8 – Two views geometry, essential matrix, fundamental matrix, rectification
- Topic 9 – Triangulation, Structure From Motion
- Topic 10 – Deep learning, CNN

מושגים:

- **היסטוגרמה** - היסטוגרמת תמונה מתארת את פילוג רמות האפור על פני התמונה. מציין את השכיחות היחסית של רמת האפור בתמונה לפי הנוסחה הבאה:

To normalize (probability):

$$p(r_k) = \frac{n_k}{N}$$

כאשר N - גודל התמונה, n_k - מספר הפיקסלים בעלי רמת אפור k .

- **Probability** - עבור גון כלשהו כמה פעמים הוא מופיע.
- **Intensity transform** - כשאתה עובד עם תמונות בקנה מידה אפור, לפעמים אתה רוצה לשנות את ערכי העוצמה. לדוגמה, ייתכן שתרצה להפוך את השחור ואת העוצמות הלבנות, או שתרצה להפוך את הגוונים הכהים יותר והגוונים הבהירים יותר. יישום של טרנספורמציות עוצמה מגדיל את הניגודיות בין ערכי עוצמה מסוימים, כך שתוכלו לבחור דברים בתמונה. לדוגמה, שתי התמונות הבאות מציגות תמונה לפני טרנספורמציה בעוצמה ואחריה. במקור, הזיקט של איש המצלמה נראה שחור, אך עם שינוי עוצמה, ההבדל בין ערכי

העוצמה השחורה, שהיו קרובים מדי לפני כן, הוגדל כך שהכפתורים והכיסים הפכו לנראים.



יש כמה דרכים לבצע זאת :

- Image negative : ניקח כל פיקסל ונחסיר ממנו את הערך הגבוהה ביותר- הבהיר, ז"א בגווני

אפור- 255 (בבינארי -1).

```
# Read pixels and apply negative transformation
for i in range(0, img.size[0]-1):
    for j in range(0, img.size[1]-1):
        # Get pixel value at (x,y) position of the image
        pixelColorVals = img.getpixel((i,j));

        # Invert color
        redPixel    = 255 - pixelColorVals[0]; # Negate red pixel
        greenPixel  = 255 - pixelColorVals[1]; # Negate green pixel
        bluePixel   = 255 - pixelColorVals[2]; # Negate blue pixel

        # Modify the image with the inverted pixel values
        img.putpixel((i,j),(redPixel, greenPixel, bluePixel));
```



- Log Transform $s = c \cdot \log(1+r)$ להחליף כל פיקסל בלוג שלו, למעשה נעשה זאת כאשר נרצה להעצים את הפיקסלים הנמוכים, על חשבון של אובדן מידע של הפיקסלים הכהים.



- **PDF** - probability density function פונקציית הסתברות הדחיסות של הצבעים בתמונה, עבור כל גיון אפור נחשב את ההסתברות שלו.

- **CDF** - The Normalized Histogram פונקציית חלוקה מצטברת לינארית המייצגת בהיסטוגרמה את כמות ההצטברות בכל נקודה.

סוגי תמונות:

- Intensity (or grayscale) images : תמונה אפורה
Either uint8 in the range [0,255] or doubles in the range [0,1]
- Binary images – תמונה בצבעים או שחור או לבן – 0 ו 1.
- RGB images – תמונה עם 3 מטריצות של צבע -אדום, ירוק, כחול. שכל הצבעים יחס נותנים לנו תמונה צבעונית.
- **Histogram Equalization** – כאשר נרצה לשפר את התמונה, להפוך אותה לחדה וברורה יותר נשנה את ה CDF כך שנוזיז תחילה לאמצע הסכום (למשל מ 0 עד 255 נשים ב 127) ולאחר מכן נמתח את הסכומים כך שמספר גווני האפור יהיה כמה שיותר מתוח על כל הגוונים, מ 1 עד 255. איך נעשה זאת?
דוגמה:

Formulation

- The solution ($R = g_{old}$, $S = g_{new}$)

$$g_{new} = \left\lceil G \sum_{g=g_{min}}^{g_{old}} p_{old}(g) - 1 \right\rceil$$


- Notes:

- g_{new} is unknown, g_{old} is known.
- $p_{old}(g)$ is the histogram of pixel level g , not the cumulative histogram.

החישוב שנעשה :

$$cdf_m = (cdf_m - cdf_m.min()) * 255 / (cdf_m.max() - cdf_m.min())$$

1. נעביר את המשוואה לאמצע "המערך" נרצה שחצי מהגבהים יהיו באמצע.



נעביר מ 50 ל 127 את כל ה 5000 שנמצאים בגוון 50.

2. נשמור על יחס סדר, אם פיקסל A יותר בהיר מפיקסל B נרצה שהיחס בין הצבעים ישמר במעבר.
ז"א אם כמות הפיקסלים הקטנים מפיקסל R הוא 1700 אז גם כשנעביר את פיקסל R לגוון אחר עדין יהיו 1700 פיקסלים קטנים ממנו.

$$\frac{5000}{10000} \cdot 255 = 127$$

זה החישוב שלפיו נדע איך להזיז כל סכום של אינטנסיטי,

ולשמור על היחס סדר ולדעת לאן להעביר .

שלבי האלגוריתם :

1. מחשבים הסטוגרמה של התמונה
2. מחשבים את ה cumulative ההסתברות המצטברת (ההסתברות של הפיקסל הראשון, ההסתברות של הפיקסל השני ועוד הראשון וכן הלאה..)
3. מנרמלים (לוקחים את קבוצת הפעמים שהאינטנסיטי נמצא בתמונה ומחלקים אותו במספר האינטנסיטי שיש)-אפשר לנרמל לפני.
4. מכפילים את הנרמול בערך המקסימלי של ה gray level (255).
5. מעגלים (ערך תחתון) מעתיקים את ה intensiti הקודם לחדש. ועושים ככה לכולם.
6. יכול להיות מצב שבגלל שאנחנו שומרים על יחס סדר בהעתקה אז לא נשתמש בכל טווח האינטנסיטי. לכן אחרי המעבר נמתח את הכל מ0 עד 255 מההתחלה עד הסוף (וכך נשמור על היחס).

מתי האלגוריתם לא יעבוד? ? שהנחות לא נכונות, שיש 2 תמונות יחד או שההתפזרות של ה gray level לא אותו דבר.

איך נפתור את זה?


במקרים של תמונות שה intensity צריך להיות בצורה שהיא- קיצוני לצבע מסוים. אז נצטרך לעבור ל high level – נעבד את התמונה לפי אזורים.
עבור כל חלק מהתמונה נעשה כמו שעשינו בתמונה שלמה (נחשב לאן היא צריכה לעבור בתמונה המשופרת) רק שכאן נחשב עבור האזור הקטן אבל ניקח רק את הפיקסל האמצעי ורק אותו מעבירים לאינטנסיטי של התמונה המשופרת. וכך נעשה עבור כל פיקסל בתמונה.
* בקצוות נכפיל את הערכים עד שנקבל גודל החלון.
איפה זה יכשל? במעברים, אז איזה חלון ניקח? צריך שלא יהיה קטן מידי כי אז הוא לא ישנה כלום אבל גם לא גדול מידי-שיטשטש יותר מידי.

הסבר נוסף- <https://www.youtube.com/watch?v=PD5d7EKYLcA>

Pixel Intensity	1	2	3	4	5	6	7	8	9	10
No. of pixels	1	3	3	2	2	1	3	1	0	0
Probability	.0625	.1875	.1875	.125	.125	.0625	.1875	.0625	0	0
Cumulative probability	.0625	.25	.4375	.5625	.6875	.75	.9375	1	1	1
C.P * 20	1.25	5	8.75	11.25	13.75	15	18.75	20	20	20
Floor Rounding	1	5	8	11	13	15	18	20	20	20


- **Quantization** – להפוך תמונה מהרבה גווני אפור להרבה פחות. טווח גווני האפור מצומצם יותר, נצטרך להעביר כל גוון וגוון למספר מצומצם של גווניים, שימוש- דחיסה.
הגדרה פורמלית : המרת אות אחד למשנהו תוך תחזית ערכי האות המומר לתחום (קטן בד"כ) מהתחום המקורי.
לאחר שבחרנו את מס' הצבעים, השאלה היא : איך מנפים כל גוון לגווניים המצומצמים?

נבחר סיגמנטים של חלוקה, נבחר גודל של סיגמנט (נבחר כמות סיגמנטים בהתאמה לכמות הערכים - סיגמנטים -מחיצות) ומתוך האינטרוול (בין כל 2 סיגמנטים) נבחר את הערך שנרצה. למשל עבור 3 ערכים נשים 4 סיגמנטים.



Quantization - solution

Goal: quantize the image to 3 intensities



Given: K - the number of values we want

Goal: Find the boundaries (z) and the values themselves (q)

q_i – הערך שאתה רוצה שיהיה מיינמלי.

z_i – החלוקה.

למעשה נחלק למחיצות, בתוך המחיצות נמצא את הגוון המרכזי- לפי תנאים שנחליט עליהם. וכך נסווג- כל גוון יסווג לערך (אינטרוול) שנקבע הכי קרוב אליו.

```
def kmeans(pts: np.ndarray, k: int, iter_num: int = 7) ->
(np.ndarray, List[np.ndarray]):
    """
    Calculates K-Means
    :param pts: The data, a [nXm] array, **n** samples of **m**
    dimintions
    :param k: Numbers of means
    :param iter_num: Number of K-Means iterations
    :return: [k,m] centers,
             List of the history of assignments, each assignment is a
    [n,1]
             array with assignment of each data point to center,
    """
    if len(pts.shape) > 1:
        n, m = pts.shape
    else:
        n = pts.shape[0]
        m = 1
```

```

pts = pts.reshape((n, m))
assign_array = np.random.randint(0, k, n)
centers = np.zeros((k, m))

assign_history = []
for it in range(iter_num):
    for i, _ in enumerate(centers):
        if sum(assign_array == i) < 1:
            continue
        centers[i] = pts[assign_array == i, :].mean(axis=0)

    for i, p in enumerate(pts):
        center_dist = np.sqrt((centers - p) ** 2).sum(axis=1)
        assign_array[i] = np.argmin(center_dist)
    assign_history.append(assign_array.copy())

return centers, assign_history

def quantizeImageKmeans(imOrig: np.ndarray, nQuant: int, nIter: int)
-> (List[np.ndarray], List[float]):
    """
    Quantized an image in to **nQuant** colors
    :param imOrig: The original image (RGB or Gray scale)
    :param nQuant: Number of colors to quantize the image to
    :param nIter: Number of iterations for the KMeans
    :return: (List[qImage_i], List[error_i])
    """

    gray = imOrig / imOrig.max()
    if len(gray.shape) > 2:
        data = gray.reshape((-1, 3))
        height, width, _ = gray.shape
    else:
        data = gray.reshape(-1)

    cs, assignment = kmeans(data, nQuant, nIter)

    assign_list = []
    error_list = []
    for assign_i in assignment:
        qunt_img = np.zeros(data.shape)
        for i, c in enumerate(cs):
            qunt_img[assign_i == i] = c
        qunt_img = qunt_img.reshape(gray.shape)

        error = np.sqrt(((qunt_img - gray) ** 2).sum())
        assign_list.append(qunt_img)
        error_list.append(error)

    return assign_list, error_list

```

טרנפורמציה חסרת זיכרון הממירה אות אחת לאות אחרת ע"י העתקת הערכים המותרים לאות לתחום חדש, בדרך כלל קטן יותר מהתחום המקורי.

ייצוג האות השני כרוך בשגיאה, למשל, אתהקוונטיזציה האחידה (בה המרווח בין הרמות אחיד) ניתן לתאר ע"י פונקציית המרה, ואת שגיאת הקוונטיזציה ניתן לחשב ע"י הרמות השונות של אות הכניסה.

קוונטיזציה יוניפורמית (uniform quantization):

המרווח בין רמות הקוונטיזציה אחיד (שגיאות הקוונטיזציה המקסימלית הינה מינימלית).
(חלוקה שווה בסיגמנטים, למשל אם יש לי להמיר 35 צבעים נחלק ל4 בצורה שווה).


קוונטיזציה לא יוניפורמית (non-uniform quantization):

המרווח בין רמות הקוונטיזציה אינו אחיד (עבור אינטרוולים שווים של אות כניסה). כללית, אם אות הכניסה הינה בעל פילוג $p(z)$, אזי קביעת רמות הקוונטיזציה תעשה עפ"י קריטריון השגיאה הריבועית המינימלית:

$$\epsilon^2 = \sum_{i=0}^{K-1} \int_{z_i}^{z_{i+1}} (z_i - z)^2 p(z) dz \rightarrow \min$$


- **Point operation** – (פעולת נקודה) היא שינוי לערך פיקסל המבוסס על ערך פיקסל זה ואינו תלוי במיקום או בערכים שכנים (ללא הקשר (פחות זיכרון)).
ניתן ליישם על ידי: יישום אריתמטי של קבוע, יישום לוגי של אופרטור בוליאני, שינוי היסטוגרמה.

Example: $g(x, y) = \alpha \cdot f(x, y) + \beta$




- **Geometric operations** – הפעולה תלויה בקואורדינטות של הפיקסלים. הקשר חופשי. לא תלוי בערך הפיקסלים. לרוב ישמש להזזה, הפיכה וכדו של תמונה.

Example: $g(x, y) = f(x + a, y + b)$




- **Spatial operations** – הפעולה תלויה בערך הפיקסלים ובקואורדינטות. תלוי הקשר - תלוי גם בפיקסלים הסמוכים.

Example:
$$g(x,y) = \sum_{i,j \in N(x,y)} f(i,j) / n$$



$$g(x,y) = M(\{f(i,j) | (i,j) \in N(x,y)\})$$



- **Filtering** – להריץ את אותה פונקציה עבור כל אופציה של גודל חלון בתמונה.

```

121 120 119 118 117 116 115 114 113 112 111 110 109 108 107 106 105 104 103 102 101
120 119 118 117 116 115 114 113 112 111 110 109 108 107 106 105 104 103 102 101
119 118 117 116 115 114 113 112 111 110 109 108 107 106 105 104 103 102 101
118 117 116 115 114 113 112 111 110 109 108 107 106 105 104 103 102 101
117 116 115 114 113 112 111 110 109 108 107 106 105 104 103 102 101
116 115 114 113 112 111 110 109 108 107 106 105 104 103 102 101
115 114 113 112 111 110 109 108 107 106 105 104 103 102 101
114 113 112 111 110 109 108 107 106 105 104 103 102 101
113 112 111 110 109 108 107 106 105 104 103 102 101
112 111 110 109 108 107 106 105 104 103 102 101
111 110 109 108 107 106 105 104 103 102 101
110 109 108 107 106 105 104 103 102 101
109 108 107 106 105 104 103 102 101
108 107 106 105 104 103 102 101
107 106 105 104 103 102 101
106 105 104 103 102 101
105 104 103 102 101
104 103 102 101
103 102 101
102 101
101

```

Sliding window - עבור כל פיקסל בתמונה :

ניקח גודל חלון kxk.

חישוב הפונקציה על כל הפיקסלים בחלון.

שינוי הערך של הפיקסל האמצעי בחלון לתוצאה של החישוב לפי הפונקציה.

לפונקציה קוראים - filter . (הפעולה הזו נקראת כך כיון שנעשה זאת עבור כל פיקסל בתמונה).

נעשה פעולה זאת עבור :

1. Template Matching - התאמת וזיהוי תבניות.

2. Clean noise – ניקוי רעשים מתמונה.

3. Detect Edges - זיהוי אובייקטים (edges) בתמונה ע"י זיהוי קצוות האובייקט.

- **Filter Kernel**

$$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

- -Min Filter

- -Max Filter

- רעש הערות כלליות-

במציאות הייצוג של סוגי הרעש השונים הינו דיסקרטי (ולא רציף), כלומר היסטוגרמות בניגוד ל

s'pdf

מניחים כי הרעש אינו קורלטיבי, כלומר שינויי רמות האפור (כתוצאה מהרעש) אינם תלויים

מרחבית כשעוברים מפיקסל לפיקסל, ופילוג הרעש בכל פיקסל אינו תלוי במיקום הפיקסל .

$$g(x,y) = f(x,y) + n(x,y)$$

הוספת רעש(באופן סינטיטי) לתמונה נתונה

$$g(x, y) = f(x, y) \cdot n(x, y)$$


או הכפלת התמונה ברעש

סילוק רעש multiplicative קשה יותר ומצריך עיבוד לא-ליניארי.

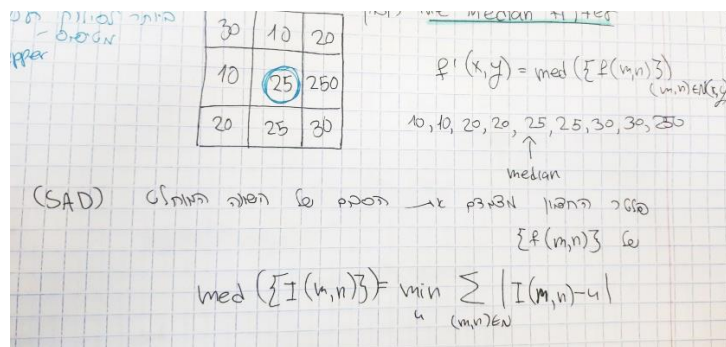
- **Salt & Pepper Noise** – (רעש מלח פלפל) הוא רעש על תמונה של כל מיני נקודות רנדומליות של לבן ושחור ז"א ערכים קיצוניים בפיקסלים מסוימים. נוצר לפעמים מחומר התמונה, הצטברות אבק במערכת האופטית וכדו. נוכל לייצר אותו באופן סינטטי ע"י המשוואה:

$$f_n(x, y) = \begin{cases} f(x, y) & \text{with probability } p \\ 255 & \text{with probability } (1-p)/2 \\ 0 & \text{with probability } (1-p)/2 \end{cases}$$

- **רעש גאوسی** -



- **The Median filter** – (חציון- בעל הביצועים הטובים ביותר לסילוק רעש מטיפוס - s&p)



Median filter algo

```

1 def medianFilter(img, ksize):
2     hsize = ksize//2
3     retImage = np.zeros(img.shape)
4     h, w = img.shape
5     for i in range(h):
6         for j in range(w):
7             box = img[i-hsize:i+1+hsize, j-hsize:j+1+hsize]
8             retImage[i, j] = np.median(box)
9     return retImage

```

- **The Average filter** – (ממוצע)

$$f'(x,y) = \text{mean}(\{f(u,v)\}_{(u,v) \in N(x,y)})$$

$$= \frac{1}{|N|} \sum_{(u,v) \in N(x,y)} I(u,v)$$

Squared difference (SSD) is the sum of squared differences between the pixel values and the mean value.

$$\text{mean}(\{I(u,v)\}) = \min_u \sum_{(m,n) \in N} (I(u,v) - u)^2$$

- **Filter, kernel and mask are the same!**

- **Convolution** – במתמטיקה (בפרט, ניתוח פונקציונלי) קונבולוציה היא פעולה מתמטית בשני פונקציות (f ו g) לייצור פונק' שלישית המבטאת את אופן שינוי הצורה של האחד על ידי האחר. (המונח קונבולוציה מתייחס הן לתפקוד התוצאה והן לתהליך המחשוב שלה. זה מוגדר כאינטגרל של המוצר משני הפונקציות לאחר שהאחת הופכת ומועברת). פעולה לינארית על אות או על שינוי האות (כמובן שכאן נשתמש בזה לשינוי תמונות) למעשה כדי להשתמש ב filter נריץ אותם כמטריצה על התמונה ע"י הפעולה קונבולושן ובכך נקבל את אפקט החלון שרצינו. הפעולה תתבצע כך : עבור כל פיקסל, ניקח חלון בגודל KxK, נחשב את הסכום של החלון ונשנה את הערך של הקורדינטה של הפיקסל.

עבור D1 : (חד ממדית)

The convolution operation is defined as:

$$h(x) = (f * g)(x)$$

where f is the signal/image and g is the mask, filter, or kernel.

$$= \sum_{i=-\infty}^{+\infty} f(x-i)g(i)$$

For a kernel $h = [2, 0, 3]$, the convolution is:

$$h(x) = (f * g)(x) = \sum_{i=-1}^{+1} f(x-i)g(i)$$

$$h(x) = 2f(x-1) + 3f(x-1)$$

עבור D2 : (דו ממדית)

https://www.youtube.com/watch?v=KTB_OFoAQcc

```
def conv2D(inImage: np.ndarray, kernel2: np.ndarray) -> np.ndarray:
    """
    Convolve a 1-D array with a given kernel
```

```

:param inImage: 2D image
:param kernel2: A kernel
:return: The convolved image
"""

inv_k = kernel2[::-1, ::-1]
kernel_shape = np.array([x for x in kernel2.shape])
img_shape = np.array([x for x in inImage.shape])
out_len = np.max([kernel_shape, img_shape], axis=0)
midKernel = kernel_shape // 2
paddedSignal = np.pad(inImage.astype(np.float32),
                      ((kernel_shape[0], kernel_shape[0]),
                       (kernel_shape[1], kernel_shape[1])),
                      'edge')

outSignal = np.ones(out_len)
for i in range(out_len[0]):
    for j in range(out_len[1]):
        st_x = j + midKernel[1] + 1
        end_x = st_x + kernel_shape[1]
        st_y = i + midKernel[0] + 1
        end_y = st_y + kernel_shape[0]

        outSignal[i, j] = (paddedSignal[st_y:end_y, st_x:end_x] *
                             inv_k).sum()

return outSignal

```

- **Correlation** – בדיקה של מדד הדמיון בין 2 דברים. (התהליך דומה לconvolution ואם ה kernel סימטרי התוצאות של שניהם יהיו זהות).
- **Smoothing by Spatial Filtering** – טשטוש ע"י kernel וקונבולוציה.
- **Template Matching** - בהינתן תמונה / אות, אנו רוצים למצוא המיקום של תבנית נתונה. כדי לבצע זאת נצטרך להבחין במספר דברים:
 1. התמונה והתבנית עשויים להיות מעט שונים אחד מהשני.
 2. אורת רעש.
 3. מודל שמיוצג ע"י כפל וחיבור.
 לכן נשתמש ב - Normalized Cross Correlation.


https://en.wikipedia.org/wiki/Template_matching#targetText=Template%20matching%20is%20a%20technique,to%20detect%20edges%20in%20images.

האלגוריתם:

1. צריך – מטריצת תבנית בגודל $K \times K$, מטריצת תמונה בגודל $N \times N$.
2. עבור כל $K \times K$ חלון אפשרי בתמונה נעשה NCC בין התבנית לחלון (חלק מהתמונה בגודל התבנית).
3. תסמן את המצב עם הערך הכי גבוה כמצב של התבנית. *****

NCC Results

- Look for the position of the maximum value



- Normalized Cross Correlation (NCC) – השוואה בין שני מטריצות.

$$\cos(\theta) \stackrel{\text{def}}{=} \frac{\vec{\alpha} \cdot \vec{\beta}}{|\vec{\alpha}| \cdot |\vec{\beta}|}$$


Zero normalized cross correlation

- $\vec{\alpha} = \vec{\alpha} - \text{mean}(\vec{\alpha})$
- Same for beta

הסבר - <https://anomaly.io/understand-auto-cross-correlation-normalized-shift/>

זוהי הדרך הנפוצה ביותר להשוואה בין תמונה לתבנית, יעבוד אפילו אם התבנית לא זהה.

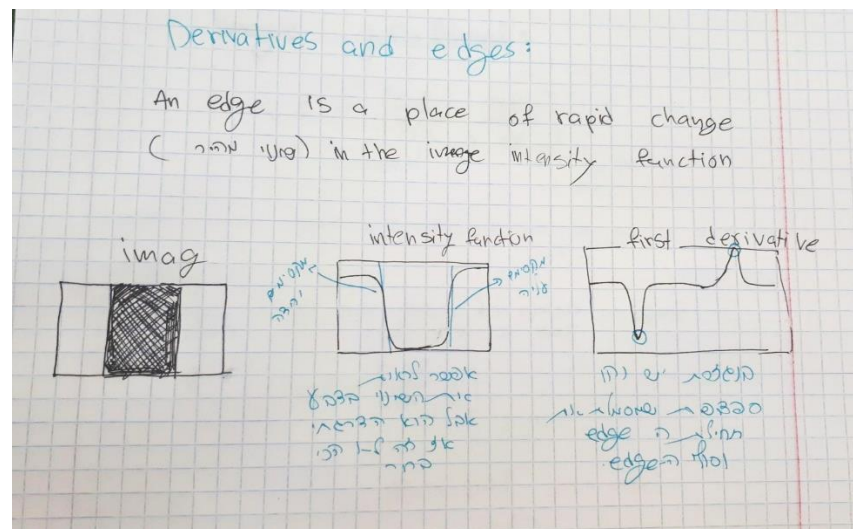
- Correlation Map



Filter Response

:Image Derivatives: Edges and Sharpening

- - Edges



$\frac{1}{2} \frac{d}{dt} \left(\frac{1}{2} m v^2 \right) = \frac{1}{2} m v \frac{dv}{dt}$

פלנטה
 image
 פלנטה

$$100 \div 10 = 10$$

1. אלוהים הוא אלוהים אחד

אברהם אבינו
אברהם אבינו

It's partial of f respect to x and the partial of f respect to y and it has both a magnitude, how quickly things are getting brighter and also you can see there's this angle, which is sort of the direction of that gradient


The gradient points in the direction of most rapid increase in intensity

●

$$\nabla f = \left[\frac{\partial f}{\partial x}, 0 \right]$$


$$\nabla f = \left[0, \frac{\partial f}{\partial y} \right]$$

$$\nabla f = \left[\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right]$$




Gradient Derivatives and Magnitude

Gradient Derivatives and Magnitude

$$|\nabla f| = \sqrt{\left(\frac{\partial f}{\partial x}\right)^2 + \left(\frac{\partial f}{\partial y}\right)^2} \quad I_x =$$


$$* \begin{bmatrix} -1 & 0 & 1 \end{bmatrix} =$$


$$\alpha = \tan^{-1} \left(\left(\frac{\partial f}{\partial y} \right) / \left(\frac{\partial f}{\partial x} \right) \right)$$


$$* \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix} =$$


$$\cos(\alpha) \frac{\partial f}{\partial x} + \sin(\alpha) \frac{\partial f}{\partial y}$$

$$\nabla f = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right) =$$

1st Derivative Gradient Magnitude

$I_x =$  $I_y =$ 

$$\sqrt{I_x^2 + I_y^2} =$$

Magnitude can be used as a simple Edge Detector

1. וקטור הגראדינט מצביע על הכיוון בו קצב השינוי של $f(x,y)$ הוא מירבי.

2. גודל הגראדינט $\sqrt{G_x^2 + G_y^2}$ שווה לקצב השינוי המירבי של $f(x,y)$ ליחידת מרחק בכיוון G .

3. כיוון הגראדינט מוגדר ע"י

$$\alpha(x, y) = \arctan\left(\frac{G_y}{G_x}\right) = \tan^{-1}\left(\frac{G_y}{G_x}\right)$$

- Edge Detection

ואיפה הוא נגמר, באיזה מיקום. בשביל זה השתמש ב gradient שיבליט לנו את השינויים בתמונה.

לכל edge ניתן לייחס עוצמה (יחסית לגודל השינוי) וכיוון (אוריינטציה), באשר הכיוון הוא בניצב


```
.edge\>(normal )
```

צעדים אופייניים ל- Edge Detection :


1. סינון ראשוני (tradeoff) בין סינון רעש לחדות ה-edges.
 2. שיפור (enhancement) למציאת ה-edges.
 3. גילוי ה-edges.
 4. מיקום (location) מחייב עבודה ברמת דיוק של תת-פיקסל (subpixel resolution).
- נקודת שפה (point edge)** - פיקסל במקום בו קיים שינוי עוצמה לוקאלי משמעותי בתמונה.
בשביל לעשות זאת נשתמש בkernel כמו-Sobel, Zero Crossing Simple, Zero Crossing LOG, Canny.

- **Blurring/Smoothing** – טשטש. תמיד טשטש את התמונה לפני ביצוע אופרטורים. הטשטוש בדרך כלל הוא box filter או Gaussian filter.

Smoothing



- **Sobel** – להחליק את התמונה לכיוון אחד, ולחשב את הנגזרת בכיוון האורתוגונלי. (כך אנחנו מורידים רעש כיווני ולא הורסים את ה-edges). בעזרת הנגזרת השנייה אני מוצא את המיקום של ה-edges כי רוב הפעמים ה-edges לא יהיה בינארי, ההבדל בינו לבין השאר הוא הדרגתי ולכן לא מיידי, הנגזרת השנייה נותנת לנו את האפשרות הזו- המספרים ה"פיקסלים" ה-edges.



*****לבדוק תקינות של הקוד*****

חשוב לשים לב – לחלק את הכל ב 1/8 (אפשר לראות בקוד בשורה האחרונה) אפשר לראות את המטריצה של sobel כאן שהיא למעשה עושה את כל הפעולה של הנגזרת והטישטוש, נעשה איתה קולנבולוציה.

```
# 3 Edge detection
def edgeDetectionSobel(I:np.ndarray) -
>(np.ndarray,np.ndarray):
    m, img_x, img_y = convDerivative(I)
```

```

m, img_x, img_y = convDerivative(m)
sobel_x = np.array([[ -1,  0,  1], [ -2,  0,  2],
[ -1,  0,  1]])
sobel_y = np.array([[ 1,  2,  1], [ 0,  0,  0], [ -1,
-2, -1]])
f_x = cv2.filter2D(img_x, cv2.CV_64F, sobel_x)
f_y = cv2.filter2D(img_y, cv2.CV_64F, sobel_y)
# (1/8)*((f_x**2 + f_y**2)**(0.5))
return (1/8)*f_x, (1/8)*f_y

```

- **Canny** - שלבי האלגוריתם:

1. Smooth נפלטת את התמונה עם נגזרת של gaussian (לפי X ו Y).

2. נמצא magnitude (גודל-יחיד) ו- orientation (הכיוון- הזיות) של הגרדיאנט.

$$|G(x,y)| = \sqrt{I_x^2 + I_y^2} \quad , \quad \alpha = \tan^{-1}\left(\frac{I_y}{I_x}\right)$$

3. ניקח את החלקים העבים של ה edge ונצר אותם.

איך נעשה את זה?

עבור כל פיקסל (x,y) מוצאים את כל הגרדיאנטים אם אתה לא פיק (local peak) ז"א החלק

שהוא משתנה מאוד מהר אז נשנה אותו ל-0.

4. Hysteresis - 1. ניקח $T_1 > T_2$ ז"א threshold.

2. כל פיקסל $|G(x,y)| < T_1$ הוא חשוך בלהיות פיקסל edge.

אם הוא שווה ומחובר ל T_2 אז גם אותו נבחר להיות חלק מ-edge.

*****לבדוק תקינות של הקוד*****

```

def edgeDetectionCanny(I:np.ndarray) -
>(np.ndarray,np.ndarray):
    I = cv2.GaussianBlur(I, (7, 7), 0)
    mag, img_x, img_y = convDerivative(I)
    D = orientation(I, img_x, img_y)
    res, weak, strong =
threshold(non_max_suppression(mag, D))
    return hysteresis(mag, weak, strong)

```

- **Hysteresis** – יחבר לנו edge שלא ניראים מחוברים בהכרח (משתמשים ברעיון זה גם ב canny).


האלגוריתם הוא:

- נשתמש ב threshold גבוה ונמוך.

- כל edge מעל הגובה- הוא edge אמיתי (נשמור אותו).

- כל edge מתחת לנמוך- הוא לא edge אמיתי (נמחק אותו).

- כל edge שהוא בין הנמוך לגבוה, נשמור אותו רק אם הוא מחובר לedge חזק (ברור).




**** - Zero Crossing Simple •

***** - Zero Crossing LOG •

• Gaussian filter – זה עוזר לי כאשר אני רוצה לתת משקל לedge, לכן נעשה נגזרת "תלת מימד" הבעיה שאם יש רעש זה ישפיעה. לכן ברגע שרוצים לטשטש תמונה- נעשה גואסיאן- תמיד עובד.

Smoothing with a 2D Gaussian Filter



• -Derivative – Numeric

קירוב נומרי לגראדינט

$$G_x \cong f[i, j + 1] - f[i, j]$$

$$G_y \cong f[i, j] - f[i + 1, j]$$

מסכות הקונבולוציה המתאימות הן:

-1	1
----	---

 G_x

1
-1

 G_y

כדי שהחישוב יתבצע ביחס לנקודה מסוימת קבועה (קרי, $[i + 1/2, j + 1/2]$) ניקח

-1	1
-1	1

 G_x

1	1
-1	-1

 G_y

ומכאן ברור כי עדיף השימוש בסביבת 3X3, למשל, כך שהגראדינט יחושב לגבי פיקסל מרכזי

• Laplacian Zero Crossing – Laplacian gaussian

- Laplacian sharpening - ????.?

- Image Sharpening - ????


- Sharpening via Laplacian Subtraction - ?????????

- איך מוצאים קו? (Line Detection) - לרצף נקודות שיקוים עבורם $y=ax+b$ - מודל זה נקרא: מודל פרמטרי.

היינו רוצים שעבור נקודה (בלי לדעת כלום מראש) נדע לאיזה קווים הנקודה יכולה להשתתף בצורה יעילה, אז אם יש כמה נקודות שקשורות לאותו קו - אז יש לנו קו בתמונה.

- Lines – Hough space – עבור כל נקודה יש ישר ב Hough spaces שבו יש את כל ה- m, b האפשריים

Recap from Hough Lines



בשבילו. ועבור 2 נק' נמצא ב- Hough space את נק' החיתוך בין הנקודות. אם נעשה את זה להרבה נקודות - החיתוך ביניהם - נימנ שלנו. אבל בעולם לא אידיאלי - הנקודות זזות ולא מדויקות לכן נ"בינים" וניקח את ה"בין" עם הכי הרבה קווים שנמצאים בו.

מה הבעיות שיש:

-הטווח אינסופי

- מה קורה שהקו מאונך? אין לנו m ...

- Hough Circles -

```
4 Hough Circles
def
houghCircle(I:np.ndarray,minRadius:float=18,maxRadius:float=20
)->np.ndarray:
    # Find circles
    rmin = 18
    rmax = 20
    steps = 100
    threshold = 0.4

    points = []
    for r in range(rmin, rmax + 1):
        for t in range(steps):
            points.append((r, int(r * math.cos(2 * pi * t /
steps)), int(r * math.sin(2 * pi * t / steps))))

    acc = defaultdict(int)
    for x, y in edgeDetectionCanny(I):
        for r, dx, dy in points:
            a = x - dx
            b = y - dy
            acc[(a, b, r)] += 1

    circles = []
```

```

for k, v in sorted(acc.items(), key=lambda i: -i[1]):
    x, y, r = k
    if v / steps >= threshold and all((x - xc) * 2 + (y -
yc) * 2 > rc ** 2 for xc, yc, rc in circles):
        print(v / steps, x, y, r)
        circles.append((x, y, r))

for x, y, r in circles:
    I.ellipse((x - r, y - r, x + r, y + r), outline=(255,
0, 0, 0))

```

---להשלים---

-----שיעור 10-----

מצגת מפורטת על השיעורים הבאים - גיאומטריה :

https://ags.cs.uni-kl.de/fileadmin/inf_ags/3dcv-ws11-12/3DCV_WS11-12_lec04.pdf

• Transformations

• Parametric (global) Transformations



affine



Projective



translation




rotation



aspect

Affine transformation



Affine transform (6 DoF) = translation + rotation +
scale + aspect ratio + shear

Preserves: Parallelism


החלפת תמונה רשת בעולם	מטריצה המיוצגת	מאפיין	דרגת המטריצה	שם המעבר
	$\begin{pmatrix} \cos \theta & -\sin \theta & t_x \\ \sin \theta & \cos \theta & t_y \\ 0 & 0 & 1 \end{pmatrix}$	מילוי, קרינה Rigid	3	rigid
	$\begin{pmatrix} k \cos \theta & -k \sin \theta & t_x \\ k \sin \theta & k \cos \theta & t_y \\ 0 & 0 & 1 \end{pmatrix}$	מילוי, קרינה Similarity	4	similarity
	$\begin{pmatrix} a & b & t_x \\ c & d & t_y \\ 0 & 0 & 1 \end{pmatrix}$	מילוי, קרינה Affine	6	affine
	$\begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$	מילוי, קרינה Projective	8	projective
	$X' = X + t$	הזזה	2	translation

Scaling - מגדילים כל אחד מהקורדינטות בקבוע. לפעמים לא נרצה שיהיה לנו שינוי בפיסקל מסוים ולכן נכפיל ואז נוזי אותי בחזרה.

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} a & 0 \\ 0 & b \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$

④ משיכה אלכסונית - מרחיב/מקטין

- **Homography** - להומוגרפיה (העתקה פרויקטיבית) יש שני שימושים:
 1. איך משטח יראה אם נוזי את המצלמה ביחס אליו (רק במשטח בדו ממד) - התאמה בין תצלומים של משטחים מזוויות שונות
 2. איך העולם נראה אם נוזי את המצלמה בזווית קטנה (בתלת ממד) - התאמה בין תצלומים של העולם בתנועה בציר אחד (?)



https://he.wikipedia.org/wiki/%D7%94%D7%A2%D7%AA%D7%A7%D7%94_%D7%A4%D7%A8%D7%95%D7%99%D7%A7%D7%98%D7%99%D7%91%D7%99%D7%AA

כשמחשבים את התנועה בתמונה אנחנו תמיד מניחים מה הייתה התנועה - מה ה motion model. ואז לפי כך מחשבים את הטרנסלציה. מה יכול לקרות? שיהיו עיוותים בתמונה כי התנועה שהנחנו לא הייתה

התזוזה היחידה (לדוגמא הנחנו תזוזה מקבילה לאדמה אבל היד של הצלם קצת גרמה לסיבוב ביחס לאדמה).

-----שיעור 11-----

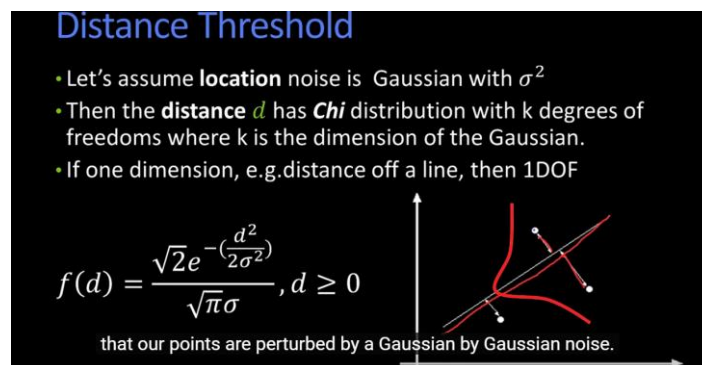
- **RANSAC** - כאשר נירצה לחבר שני תמונות (שיש להן חלק משותף-פנורמה) איך נעשה את זה? עבור general model type : כאשר ניתן לנו model type יש לו minimal set : המספר הקטן ביותר של נקודות (פיקסלים) שלפיהם המודל יוכל לחשב משוואות ישר או transform. עבור ישר- 2 נקודות אבל עבור transform? הם רק מודלים, ולכן המינימום סט של נקודות שצריך עבור transform שונות? נצטרך רק אחד, מדוע? כי ברגע שיש לי נקודה אחת בתמונה 1 אני יודעת לחשב לאן היא זזה בתמונה השנייה ולפי זה אני יכולה לחשב את כל התזוזה של כל הפיקסלים. (ע"י מה שלמדנו למציאת רמת השינוי בין שני תמונות- נעשה חישוב לא והי ולפיהם נימצא את ה-subtract). homography- נצטרך 4 נקודות כדי לחשב זאת, מדוע? כי לכל מצלמה צריך 2 נקודות.

האלגוריתם :

- הנחה : שניקח כל מיני סטים של נקודות ומתישהו נמצא סט שרוב הנקודות שלנו נמצאות על הקו.
1. רנדומלית ניבחר s נקודות (זוגות נקודות) כדי להציג דוגמה (לפי ההנחה).
 2. Instantiate the model- ליישר את המודל-- לראות כמה נקודות נמצאות על הישר שמצאנו.
 3. Get consensus set C_i – the points within error bounds (distance threshold) of the model.
 4. If $|C_i| > T$, terminate and return model.
 5. repeat for N trials, return model with max $|C_i|$.
- בגדול- ניקח סטים -החשב את הישר ביניהם (נוציא נקודות שהורסות את הישר לרוב הנקודות)(ונחשב כמה נקודות (אחרות) אכן קרובות לישר הזה (נמצאות בתוך inlier) אם הthreshold נמוך יותר ממה שמצאנו לפני- נחליף, נחזיר למעשה את הסט עם מספר הנקודות המקסימלי שנמצאות על הישר או הכי קרובות אליו, לפי ישר זה נחשב את החיבור בין כל שאר הנקודות בין שני התמונות וכדו.

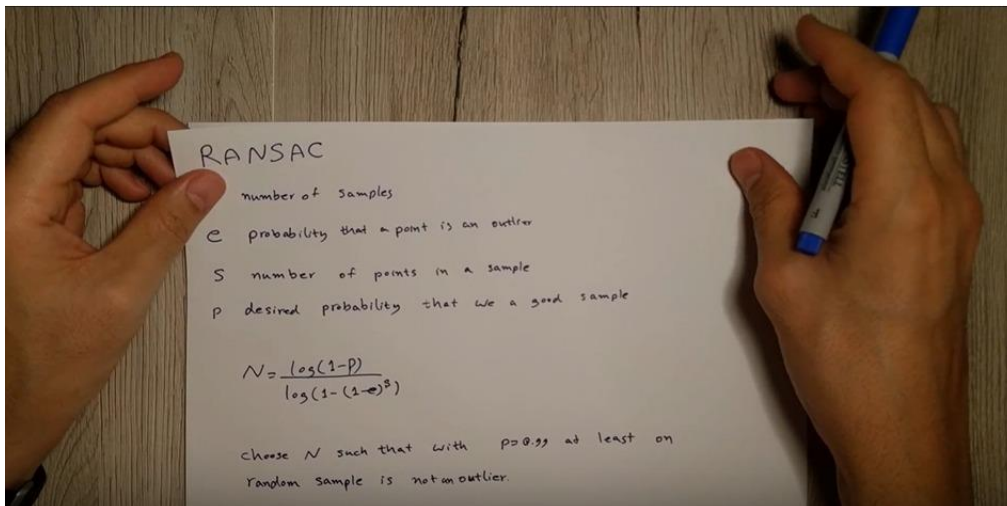
בחירת הפרמטרים :

1. עבור כל מודל מסוים נצטרך למצוא עבור מספר נקודות מסוים את המשוואות ביניהם, למשל בין ישרים- 2 נקודות בין homography נצטרך למצוא 4 נקודות והמשוואות שלהם לפיהם נידע איך לחבר את התמונה, איך התמונה זזה מנקודות אלו לנתונה השניה.
2. המרחק של ה threshold צריך להחליט מה הגבול שנחשב בתוך הישר-inlier.



3. מהו מספר הפעמים שנחפש סט למשוואה? נרצה לבחור N יחסית גדול, נצטרך לחשב את אחוז

הטעות שלפיו נידע מהו N שלנו :



כאשר c הוא ההסתברות שהנקודה היא outlier - למעשה נחפש את ההסתברות שזה אכן בתוך הקו-
inliner.

p הוא ההסתברות הרצויה - שאנו מחשיבים לטובה - למשל 99%.
 s - מספר הנקודות שבמודל.

המכנה מחשב לנו מה ההסתברות שלפחות נקודה אחת במודל או יותר הם inliner.

הסבר - https://www.youtube.com/watch?v=UKhh_MmGIjM

הסבר ב udacity -

<https://classroom.udacity.com/courses/ud810/lessons/3189558841/concepts/3167938>

[9260923](#)

- **Camera calibration** – כיול (בדיקה כמה הכלי מדידה מדויק)מצלמה הוא הוא תהליך של הערכת פרמטרים של המצלמה באמצעות תמונות של דפוס כיול מיוחד. הפרמטרים כוללים camera intrinsics. למעשה זה תהליך של הערכת פרמטרים מהותיים ו / או חיצוניים. פרמטרים פנימיים עוסקים במאפיינים הפנימיים של המצלמה, כמו אורך המוקד שלה, הסטייה, העיוות ומרכז התמונה. פרמטרים קיצוניים מתארים את מיקומו ואת התמצאותו בעולם. הכרת פרמטרים מהותיים היא צעד ראשון חיוני לראיית מחשב תלת ממדית, מכיוון שהיא מאפשרת להעריך את מבנה הסצנה במרחב האוקלידיסטי ומסלקת את עיוות העדשות, המשפיל את הדיוק. BoofCV מספק כיול אוטומטי לחלוטין למספר סוגי יעדים מישוריים (ראה תמונות לעיל) הניתנים להדפסה בקלות על נייר בגודל סטנדרטי.